

寇雯博

(+86) 155 3393 0912 ◊ kouwenboen@163.com ◊ [Homepage](#)

教育背景

西安电子科技大学, Xi'an, P.R.China

Aug, 2018 – Jul, 2022

数学与统计学院 数学与应用数学 学士学位 GPA: 3.9/4.0

- 2018–2022 Dean's List at Xidian University
- 2019–2020 National Undergraduate Training Programs for Innovation and Entrepreneurship

加州大学伯克利分校, Berkeley, CA

Jan, 2021 – Dec, 2021

Visiting student, EECS & STAT; GPA: 4.0/4.0

工作经历

LLM 算法工程师, 拼多多

Aug, 2024 – so far

负责面向电商售前场景的 *Agent Harness* 研发, 围绕 *Context Engineering*、*Tool Use*、*Memory*、*LLM Inference* 与 *Evaluation* 持续提升 *Agent* 在真实任务中的执行能力

- 负责商家售前 *Agent Harness* 的整体设计, 构建 Trigger → Retrieval → Reasoning → Tool Use → Risk Control 的执行流程, 实现模型、知识库与工具调用协同完成复杂售前任务
- 设计 *Context Engineering* 策略, 对商家历史 QA、多轮对话及商品知识进行压缩、筛选与动态组织, 结合 RAG 按需召回相关知识, 在有限 *Context Window* 内最大化保留相关信息, 提高回复质量
- 设计 *Tool Use* 流程, 使模型按需调用商品售后率、相似商品统计等工具, 将外部信息纳入推理过程, 提高复杂售前问题的回答能力及用户信任度
- 优化在线推理性能, 包括 Prompt 排版优化以提高 Prefix Cache 命中率、模型路由、Reasoning Compression、DSpark 推理加速、模型量化, 以及 vLLM/SGLang 推理参数调优, 在计算资源受限场景下降低推理延迟
- 负责售前回复模型训练方案设计, 构建训练数据并设计多目标 Reward Function, 通过思维链训练及强化学习持续优化模型在真实业务场景中的表现
- 建立 *Agent Evaluation* 体系, 结合日志分析、错误归因、回复率、转人工率及询单转化率等, 持续迭代 *Agent* 能力

AI 工程师, 华为

Aug, 2022 – Aug, 2024

构建语音助手小艺的记忆能力

Apr, 2024 – Aug, 2024

- 负责语音助手长期 Memory 能力建设, 设计 Long-term Memory Management、Memory Retrieval 与 Graph RAG 流程, 构建用户 Memory Graph, 为 LLM 提供结构化长期记忆及跨记忆关联推理能力
- 持续优化 Memory Retrieval, 包括检索融合、记忆改写、重排序等策略, 提高长期记忆检索准确率

构建集团财经的数据语义图谱

Aug, 2022 – Apr, 2024

- 主导财经知识图谱 Schema 设计，构建模型层、语义层、物理元数据三层体系
- 作为项目 Leader 完成知识图谱平台设计及多个财经智能分析应用落地

计算机视觉工程师实习生, **HeyGen**

Feb, 2022 – May, 2022

参与 AI 视频生成引擎研发

- 提出面向虚拟 3D 头像生成的人脸匹配算法，并构建高质量人脸数据集微调 GFPGAN 模型，提升 AI 生成视频中人物面部一致性 & 牙齿生成质量

SELECTED PUBLICATIONS

- First-author, *ACTA PHYSICA SINICA*, 2021, 70(3): 030701.
- Co-author, *Computer Methods in Applied Mechanics and Engineering*, 2021, 374: 113591.
- Co-author, *Communications in Computational Physics*, 2022, 31(2): 593-625..

编程技能

AI Native 开发: Claude Code, Codex, MCP

Harness 工程: Context Engineering, Memory, Tool Use, RAG, Evaluation

LLM 推理: vLLM, SGLang, KV Cache Optimization, Model Quantization

LLM 训练: LLaMA Factory, ms-swift, verl, Megatron-LM

编程语言: Python, Java, SQL, Cypher